INSTITUTO FEDERAL DE EDUCAÇÃO DE MATO GROSSO – IFMT

DEPARTAMENTO DE COMPUTAÇÃO

DISCIPLINA DE MINERAÇÃO DE DADOS - 2026/2

PROJETO PRÁTICO DE ETL
MERCATTO VAREJO: INTEGRAÇÃO DE FONTES HETEROGÊNEAS E PREPARAÇÃO DE DADOS PARA MINERAÇÃO

Projeto em equipe · 4 semanas

Prof. Orlando Júnior

Este roteiro deve ser lido junto com o referencial teórico da disciplina, *ETL como preparação de dados na mineração de dados*. Os sete princípios de desenho enunciados na seção 6 daquele texto são a razão de ser de cada exigência feita aqui, inclusive das que, à primeira vista, parecem excesso de rigor.

SUMÁRIO

1 APRESENTAÇÃO E OBJETIVOS 3

1.1 Objetivos de aprendizagem 3

1.2 Organização e prazos 3

2 O CENÁRIO 4

2.1 As quatro fontes 4

2.2 O que já está pronto e o que é seu 4

3 CRONOGRAMA E ATIVIDADES 5

3.1 Semana 1 — Perfilar antes de tocar 5

3.2 Semana 2 — Extrair e conformar 5

3.3 Semana 3 — Carregar e verificar 6

3.4 Semana 4 — Modelar, comparar e defender 6

4 O REGISTRO DE DECISÕES DE TRANSFORMAÇÃO 6

5 O EXPERIMENTO DE VAZAMENTO 7

6 ENTREGÁVEIS 7

7 CRITÉRIOS DE AVALIAÇÃO 8

7.1 Sobre o uso de assistentes de IA 9

8 AMBIENTE E PRIMEIROS PASSOS 9

REFERÊNCIAS 10

1 APRESENTAÇÃO E OBJETIVOS

Até aqui, nesta disciplina, os dados chegaram prontos. Você recebeu uma tabela, escolheu um algoritmo, comparou métricas. Este projeto inverte a proporção: o algoritmo é o passo mais curto, e quase todo o trabalho está em construir a tabela que ele vai consumir.

A Mercatto Comércio S.A. é uma rede varejista fictícia que, em março de 2024, adquiriu uma operação nativamente digital. Desde então mantém dois sistemas em paralelo, com clientes que compram nos dois, cadastros que não conversam e um dicionário de dados incompleto. Você recebeu quatro fontes: dois bancos de dados de tecnologias diferentes, um CSV exportado à mão e um JSON de API. Precisa entregar um repositório analítico integrado e uma resposta a uma pergunta preditiva.

Nada nesses dados é impossível de resolver. Algumas coisas, porém, são **indecidíveis**: não há informação suficiente para saber qual é a resposta certa, e você terá de escolher um critério, assumi-lo e declarar o que perde com ele. Essa é a parte do projeto que mais vale nota.

1.1 Objetivos de aprendizagem

Ao final do projeto, você deve ser capaz de:

a) perfilar fontes heterogêneas e produzir um diagnóstico quantificado do que há nelas, antes de qualquer transformação;

b) distinguir heterogeneidade sintática, estrutural e semântica, e reconhecer que só as duas primeiras se resolvem com ferramenta;

c) declarar o grão de uma tabela-fato e sustentar essa declaração ao longo de todo o pipeline;

d) projetar e justificar regras de deduplicação, conformação e tratamento de ausências, explicitando o que cada regra descarta;

e) implementar verificações de qualidade ao longo do pipeline, e não apenas ao final;

f) identificar, produzir e corrigir vazamento de dados, medindo seu efeito sobre o desempenho aparente de um modelo;

g) entregar um pipeline que outra pessoa consiga executar do zero e obter exatamente o mesmo resultado.

1.2 Organização e prazos

Equipes de até **3 estudantes**. Quatro semanas, com entrega parcial ao fim de cada uma das três primeiras e entrega final com defesa na quarta. As entregas parciais não são opcionais: sem o diagnóstico da Semana 1, o trabalho da Semana 2 é feito às cegas.

Todo o trabalho acontece no ambiente containerizado fornecido. Não é permitido corrigir dados diretamente nas origens - os usuários de acesso são somente leitura, de propósito. Na vida profissional, quase nunca se tem permissão de escrita no sistema de quem produz o dado.

2 O CENÁRIO

A diretoria da Mercatto quer saber, para cada cliente, se ele voltará a comprar nos próximos três meses. A área de marketing pretende usar a resposta para dimensionar uma campanha de retenção. A pergunta, formalizada:

Dado o comportamento de compra do cliente até 30 de junho de 2025, ele realizará ao menos uma nova compra entre 1º de julho e 28 de setembro de 2025?

A pergunta é simples. O que não é simples é chegar a uma tabela em que cada linha seja um cliente - porque "um cliente" é justamente uma das coisas que os dados não definem com clareza.

2.1 As quatro fontes

Fonte	Tecnologia	Características	Volume
ERP legado	MySQL 8, charset latin1	Nomenclatura em português, caixa alta, CPF com máscara, categoria em texto livre, sem integridade referencial	≈ 577 mil linhas
Plataforma de e-commerce	PostgreSQL 16, UTF-8	Nomenclatura em inglês, taxonomia de categorias controlada, CPF sem máscara, timestamps com fuso	≈ 1,37 milhão de linhas
Atendimentos do SAC	CSV	latin-1, separador ponto e vírgula, decimal com vírgula, data dd/mm/aaaa, campos com quebra de linha, linhas repetidas	≈ 96 mil linhas
Avaliações do marketplace	JSON (NDJSON)	UTF-8, estrutura aninhada, esquema irregular, chaves opcionais omitidas, tipos inconsistentes	≈ 160 mil objetos

Ao todo, cerca de **2,2 milhões de registros**. O volume não é decorativo: enquanto o conjunto couber na tela, a tentação é corrigir anomalias uma a uma. A partir dessa ordem de grandeza, a correção precisa ser formulada como regra — e formular a regra é o objetivo.

2.2 O que já está pronto e o que é seu

Entregue pronto	**Construído por você**
Ambiente Docker com os três bancos	Todo o pipeline de extração, transformação e carga
Geração determinística dos dados	As regras de conformação e deduplicação
DDL do esquema estrela do destino	O povoamento das dimensões e dos fatos
Framework de asserções de qualidade	As asserções específicas de cada etapa
Script de perfilamento (modelo)	O diagnóstico das quatro fontes
Exportador para o Orange	A tabela-base de análise e os fluxos no Orange
Dicionário de dados (incompleto)	A reconstrução do que o dicionário não informa

3 CRONOGRAMA E ATIVIDADES

3.1 Semana 1 — Perfilar antes de tocar

Suba o ambiente e execute o script de perfilamento. Leia a saída inteira. Só então comece a pensar em transformação.

Perfilar é descrever o que existe, não julgar. A tentação de já ir corrigindo é forte e deve ser resistida: quem corrige antes de descrever perde a chance de perceber padrões que só aparecem no conjunto.

Entrega 1 — Relatório de Diagnóstico (máximo 6 páginas), respondendo:

a) Quais campos são candidatos a chave de junção entre as fontes? Qual a cobertura real de cada candidato, em número absoluto e percentual?

b) Onde há heterogeneidade semântica — o mesmo rótulo com significados diferentes entre sistemas? Apresente ao menos três casos, cada um com evidência numérica.

c) `VALOR_TOTAL` no legado e `total_amount` no e-commerce medem a mesma coisa? Prove sua resposta reconciliando cada um com a soma dos itens do pedido.

d) Quais anomalias você consegue quantificar agora, e quais só aparecerão depois da integração? Por quê?

e) Qual é o grão pretendido de cada tabela-fato? Escreva a frase completa: "uma linha de `dw.fato_pedido` representa _____". Se precisar de um "e também", o grão está errado.

3.2 Semana 2 — Extrair e conformar

Implemente a extração para a camada `stg` e as decisões de conformação. Esta é a semana mais longa e a mais valiosa. Cada decisão tomada aqui vira uma ficha do Registro de Decisões de Transformação.

As seis decisões obrigatórias estão marcadas no esqueleto do código:

1. identidade do cliente entre os dois sistemas;
2. conformação dos status de pedido, incluindo a recusa de pagamento;
3. semântica dos valores monetários;
4. mapeamento da taxonomia de produtos;
5. classificação e tratamento de cada tipo de ausência;
6. ligação das fontes de arquivo aos pedidos.

Entrega 2 — RDT parcial com as fichas 01 a 09, mais o código da extração e da transformação funcionando.

3.3 Semana 3 — Carregar e verificar

Popule o esquema estrela e construa a tabela-base de análise. Implemente as asserções de qualidade de cada etapa.

Uma exigência específica desta semana: a **reconciliação financeira**. A soma de `valor_total` no seu DW, por sistema de origem, deve ficar dentro de 0,1% do total calculado diretamente na origem. É assim que se prova que a carga não perdeu nem inventou nada — e é a verificação que mais frequentemente revela junções mal feitas.

Entrega 3 — DW carregado, com a tabela `qa.execucao_assercao` preenchida e as fichas 10 a 13 do RDT.

3.4 Semana 4 — Modelar, comparar e defender

Construa as duas versões da tabela-base de análise, exporte para o Orange, monte os fluxos e compare. Prepare a defesa.

Entrega final: repositório completo, RDT integral, fluxos do Orange (arquivos `.ows`), relatório de resultados e defesa oral de 15 minutos por equipe.

4 O REGISTRO DE DECISÕES DE TRANSFORMAÇÃO

O RDT é o artefato central do projeto e vale 30% da nota. Ele não descreve o que o código faz — o código já faz isso. Ele registra por que cada decisão foi tomada, o que se perdeu ao tomá-la e quantos registros foram afetados.

Cada ficha precisa conter, obrigatoriamente:

a) **o que o dado mostrava** — a evidência quantificada que motivou a decisão;

b) **as alternativas consideradas** — no mínimo duas, descritas com honestidade;

c) **a decisão e sua justificativa** — por que esta e não a outra;

d) **o que se perde** — toda transformação descarta algo; nomeie o quê;

e) **os registros afetados** — número absoluto e percentual da base;

f) **a asserção associada** — qual verificação do pipeline guarda essa decisão.

Uma decisão sem (d) e (e) não conta como decisão registrada. O modelo com uma ficha de exemplo integralmente preenchida está em `docs/MODELO_RDT.md`.

A razão dessa exigência é a que o referencial teórico da disciplina desenvolve: a transformação é o ponto do processo em que o julgamento do analista entra nos dados e permanece lá, invisível, até que alguém pergunte de onde veio aquele número. O RDT é a resposta antecipada a essa pergunta.

5 O EXPERIMENTO DE VAZAMENTO

Vazamento de dados é a introdução, no conjunto de treinamento, de informação sobre o alvo que não estaria legitimamente disponível no momento da predição. É a causa mais comum de modelos que funcionam brilhantemente no laboratório e fracassam em produção.

Neste projeto você vai **produzi-lo de propósito**, para depois medi-lo. Construa duas versões da tabela-base de análise:

Versão	Como é construída	Para que serve
Correta	Todo atributo calculado apenas com dados anteriores a 30/06/2025	É a versão que responde à pergunta
Com vazamento	Dois atributos calculados sobre a base inteira, mais uma normalização feita antes da partição treino/teste	É o contraexemplo, e o objeto do experimento

No Orange, monte o mesmo fluxo para as duas: amostragem estratificada 70/30, Naive Bayes, Logistic Regression e Tree, avaliados por `Test & Score`, `Confusion Matrix` e `ROC Analysis`. A única diferença entre os dois fluxos deve ser o arquivo de entrada.

O relatório de resultados deve responder três perguntas, nesta ordem:

a) Qual a diferença de desempenho entre as duas versões, medida em AUC e em acurácia balanceada?

b) O vazamento sutil — a normalização feita antes da partição — produziu diferença perceptível? Qual, em números?

c) **Se você tivesse recebido apenas o resultado da versão com vazamento, sem saber como ela foi construída, como descobriria que ele está errado?** Esta é a pergunta que será feita na defesa.

6 ENTREGÁVEIS

#	Entregável	Formato	Quando
1	Relatório de Diagnóstico das quatro fontes	PDF, até 6 páginas	Fim da Semana 1
2	RDT parcial (fichas 01 a 09) e código das etapas 1 e 2	Markdown ou PDF + repositório	Fim da Semana 2
3	DW carregado, asserções registradas, fichas 10 a 13	Repositório + dump SQL	Fim da Semana 3
4	RDT integral (fichas 01 a 15) com tabela-resumo e reflexão	PDF	Entrega final
5	Pipeline completo e reexecutável do zero	Repositório Git	Entrega final
6	Fluxos do Orange das duas versões	Arquivos .ows + capturas	Entrega final
7	Relatório de resultados do experimento de vazamento	PDF, até 4 páginas	Entrega final
8	Defesa oral	15 minutos por equipe	Semana 4

O entregável 5 é verificado assim: apaga-se tudo, sobe-se o ambiente de novo e executam-se os seis comandos do pipeline na ordem. O resultado precisa ser idêntico ao entregue. A semente do gerador é fixa, então não há desculpa de variação aleatória.

```
docker compose down -v && rm -rf dados saida
docker compose up -d --build
docker compose exec etl python 01_extracao.py
docker compose exec etl python 02_transformacao.py
docker compose exec etl python 03_carga_dw.py
docker compose exec etl python 04_abt.py --correta
docker compose exec etl python 04_abt.py --vazamento
docker compose exec etl python 05_exportar_orange.py
```

7 CRITÉRIOS DE AVALIAÇÃO

Critério	O que se avalia	Peso
Registro de Decisões de Transformação	Presença das seis partes obrigatórias em cada ficha; qualidade das alternativas consideradas; honestidade sobre o que se perdeu; quantificação dos registros afetados	30%
Corretude do DW e da ABT	Grão declarado e sustentado; ausência de chaves órfãs; reconciliação financeira dentro de 0,1%; contrato da ABT respeitado; nenhum atributo posterior à data de corte	20%
Experimento de vazamento e análise	As duas versões construídas corretamente; comparação com métricas; resposta fundamentada sobre como detectar vazamento sem conhecer sua origem	15%
Perfilamento e diagnóstico	Cobertura das quatro fontes; quantificação das anomalias; identificação dos casos de heterogeneidade semântica; prova sobre a semântica dos valores	15%
Reprodutibilidade do pipeline	Execução do zero sem intervenção manual; resultado idêntico; asserções registradas em qa.execucao_assercao; organização do repositório	15%
Defesa oral	Clareza; domínio das decisões tomadas pela equipe; capacidade de responder por escolhas feitas por outro integrante	5%

Um pipeline com decisões bem fundamentadas e desempenho preditivo modesto vale mais, nesta avaliação, que um pipeline de decisões não documentadas com AUC alta. Isso não é rigor decorativo: é a aplicação direta do argumento desenvolvido no referencial teórico da disciplina.

7.1 Sobre o uso de assistentes de IA

É permitido e esperado. O que se avalia não é a autoria de cada linha de código, mas a capacidade de justificar cada decisão — e essa justificativa será cobrada oralmente, de qualquer integrante da equipe, sobre qualquer parte do trabalho. Uma equipe que não souber explicar uma decisão registrada no seu próprio RDT perde a pontuação da ficha correspondente.

8 AMBIENTE E PRIMEIROS PASSOS

Requisitos: Docker e Docker Compose v2, 8 GB de RAM recomendados, cerca de 2 GB livres em disco, e o Orange Data Mining instalado na máquina (ele não roda em contêiner). Para subir tudo:

```
cp .env.example .env
docker compose up -d --build
docker compose logs -f seed
```

A geração e a carga levam de três a cinco minutos. Em máquinas com menos de 8 GB de RAM, ajuste `ESCALA=0.2` no arquivo `.env` antes de subir.

Primeiro comando depois que o ambiente estiver pronto:

```
docker compose exec etl python 00_perfilamento.py
```

Os acessos às origens são somente leitura (`etl_ro` / `etl_ro`). O Adminer, em `http://localhost:8080`, permite inspecionar as três bases pelo navegador. O `README.md` do repositório traz a lista de problemas comuns e como sair deles.

Uma observação final. Ao longo deste projeto você vai decidir o que conta como duplicata, o que significa uma ausência e qual é a unidade de análise. Em um sistema real de varejo, essas decisões determinam quem recebe uma oferta de retenção e quem não recebe. Em um sistema educacional — o campo em que boa parte de vocês vai trabalhar —, determinam quem é sinalizado como em risco de evasão. Vale carregar essa consideração enquanto se escreve a regra.

REFERÊNCIAS

DEMŠAR, Janez *et al.* Orange: data mining toolbox in Python. **Journal of Machine Learning Research**, v. 14, p. 2349-2353, 2013.

EHRLINGER, Lisa; WÖSS, Wolfram. A survey of data quality measurement and monitoring tools. **Frontiers in Big Data**, v. 5, art. 850611, 2022. DOI: 10.3389/fdata.2022.850611.

KAUFMAN, Shachar; ROSSET, Saharon; PERLICH, Claudia. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, art. 15, 2012. DOI: 10.1145/2382577.2382579.

KIMBALL, Ralph; CASERTA, Joe. **The data warehouse ETL toolkit**: practical techniques for extracting, cleaning, conforming, and delivering data. Indianapolis: Wiley, 2004.

KIMBALL, Ralph; ROSS, Margy. **The data warehouse toolkit**: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.

MARTÍNEZ-PLUMED, Fernando *et al.* CRISP-DM twenty years later: from data mining processes to data science trajectories. **IEEE Transactions on Knowledge and Data Engineering**, v. 33, n. 8, p. 3048-3061, 2021. DOI: 10.1109/TKDE.2019.2962680.