INSTITUTO FEDERAL DE EDUCAÇÃO DE MATO GROSSO
DEPARTAMENTO DE COMPUTAÇÃO
ENGENHARIA DE COMPUTAÇÃO
MINERAÇÃO DE DADOS

# ETL COMO PREPARAÇÃO DE DADOS NA MINERAÇÃO DE DADOS: FUNDAMENTOS, DECISÕES E IMPLICAÇÕES DIDÁTICAS

Referencial teórico

Cuiabá/MT - 2026

**RESUMO**

Este referencial examina o processo de extração, transformação e carga (ETL) a partir de um recorte específico: seu lugar como infraestrutura operacional da etapa de preparação de dados nos modelos de processo da descoberta de conhecimento em bases de dados. A literatura sobre ETL consolidou-se na tradição do data warehousing, enquanto a literatura sobre pré-processamento consolidou-se na tradição do KDD e do aprendizado de máquina; as duas raramente dialogam nos materiais didáticos brasileiros. O texto sustenta que essa separação tem custo pedagógico mensurável e propõe uma leitura integrada, na qual a etapa de transformação é tratada não como operação técnica neutra, mas como o momento em que decisões de natureza conceitual — o que conta como duplicata, o que significa um valor ausente, qual é a unidade de análise — são inscritas de forma irreversível no conjunto que alimentará o algoritmo. Ao final, derivam-se princípios para o desenho de um laboratório prático com fontes heterogêneas.

**Palavras-chave:** ETL. Pré-processamento de dados. Mineração de dados. CRISP-DM. Qualidade de dados.

# Sumário

1 INTRODUÇÃO ..... 1

2 DO KDD AO CRISP-DM: ONDE O ETL SE ALOJA ..... 2

2.1 A preparação de dados nos modelos de processo ..... 2

2.2 A tradição do data warehousing ..... 3

2.3 Convergência, tensão e uma proposta de leitura ..... 4

3 AS TRÊS OPERAÇÕES ..... 4

3.1 Extração: o encontro com a heterogeneidade ..... 4

3.2 Transformação: a etapa epistemicamente densa ..... 5

3.3 Carga: fixar a estrutura do destino ..... 7

4 QUALIDADE DE DADOS: CRITÉRIO, NÃO ETAPA ..... 7

5 UMA OBJEÇÃO SÉRIA: O ETL ESTARIA SUPERADO? ..... 8

6 IMPLICAÇÕES DIDÁTICAS: PRINCÍPIOS PARA UM LABORATÓRIO DE ETL ..... 10

7 LIMITES DESTE REFERENCIAL ..... 11

8 CONSIDERAÇÕES FINAIS ..... 12

REFERÊNCIAS ..... 14

## 1 INTRODUÇÃO

Há um descompasso recorrente no ensino de mineração de dados. O estudante aprende a comparar classificadores, a interpretar uma matriz de confusão e a discutir o compromisso entre viés e variância, mas recebe os dados já tabulados, já limpos e já em formato único. Quando esse mesmo estudante encontra um problema real, descobre que a tabela não existia: existiam três bancos de dados com chaves incompatíveis, um arquivo CSV exportado com separador decimal trocado e um conjunto de respostas em JSON aninhado. A etapa que consome a maior parte do esforço em projetos de análise é justamente aquela que o percurso formativo costuma pular.

Esse descompasso não decorre de desatenção dos docentes. Ele reproduz, no plano didático, uma divisão que já existe na literatura. De um lado, a tradição do data warehousing produziu um corpo robusto sobre ETL — sigla de extract, transform, load, o conjunto de processos de software que alimentam e atualizam um repositório analítico (VASSILIADIS, 2009) —, com atenção a arquitetura, modelagem de fluxos e desempenho (KIMBALL; CASERTA, 2004; ALI; WREMBEL, 2017). De outro, a tradição da descoberta de conhecimento em bases de dados (KDD, do inglês knowledge discovery in databases) produziu um corpo igualmente robusto sobre pré-processamento — limpeza, integração, redução e transformação de atributos (HAN; KAMBER; PEI, 2011; GARCÍA; LUENGO; HERRERA, 2015). As duas literaturas descrevem operações que se sobrepõem em boa medida, mas partem de perguntas distintas e quase não se citam.

O problema que orienta este texto pode ser formulado assim: **o que se perde, conceitual e pedagogicamente, quando ETL e pré-processamento são ensinados como assuntos separados — e o que se ganha ao tratá-los como dois recortes de um mesmo trabalho?**

A tese que sustento é que o ETL não é uma etapa anterior à mineração de dados, mas a materialização técnica de decisões analíticas. A escolha de uma regra de deduplicação, o critério de imputação de ausências, a definição da granularidade do registro carregado: cada uma dessas operações fixa o que o algoritmo poderá ou não poderá aprender. Tratá-las como preliminares administrativas é o que produz, mais adiante, resultados aparentemente excelentes e substantivamente inválidos.

A **contribuição original** deste referencial, em relação ao que já circula na bibliografia da área, é dupla. Primeiro, ele articula explicitamente as duas tradições citadas — algo que a literatura em língua portuguesa sobre mineração de dados, quando trata de pré-processamento,

geralmente faz de modo lateral, sem incorporar o vocabulário e os problemas de projeto acumulados pela pesquisa em ETL. Segundo, ele converte essa articulação em critérios de desenho de atividade prática, formulando um conjunto de princípios didáticos que justificam por que um laboratório de ETL precisa de fontes heterogêneas, volume não trivial e ambiguidade deliberada para produzir aprendizagem — e não apenas execução de roteiro. Trata-se, portanto, de um texto de fundamentação que se pretende também operacional.

O argumento se desenvolve em seis movimentos. A seção 2 situa o ETL nos modelos de processo do KDD e do CRISP-DM. A seção 3 examina as três operações que a sigla nomeia, com atenção especial à transformação. A seção 4 trata a qualidade de dados como critério transversal, e não como fase. A seção 5 confronta a tese aqui defendida com a posição contrária, hoje dominante no mercado, de que o ETL estaria superado pelo ELT e pelas arquiteturas de data lake. A seção 6 extrai as implicações didáticas. A seção 7 declara os limites do que foi argumentado.

## 2 DO KDD AO CRISP-DM: ONDE O ETL SE ALOJA

### 2.1 A preparação de dados nos modelos de processo

O artigo fundador de Fayyad, Piatetsky-Shapiro e Smyth (1996) estabeleceu a distinção que ainda organiza o campo: a mineração de dados é uma etapa dentro de um processo maior, o KDD, que compreende seleção, pré-processamento, transformação, mineração propriamente dita e interpretação/avaliação. A formulação é frequentemente citada de modo decorativo, mas seu conteúdo é preciso: os autores separam pré-processamento de transformação. O primeiro trata de tornar os dados utilizáveis — remover ruído, decidir estratégias para campos ausentes, tratar inconsistências. O segundo trata de torná-los adequados ao método escolhido — reduzir dimensionalidade, derivar atributos, mudar representações.

Essa separação importa. Limpar um conjunto é uma operação que se pode julgar, em larga medida, por critérios internos ao próprio dado: um CPF com quinze dígitos está errado independentemente do algoritmo que virá depois. Transformar é diferente: discretizar uma variável contínua em faixas só faz sentido em função de uma hipótese sobre o fenômeno e sobre o método. A primeira operação responde à pergunta "este dado está correto?"; a segunda, à pergunta "este dado está correto *para quê*?".

O CRISP-DM (*Cross-Industry Standard Process for Data Mining*) reorganizou esse mesmo terreno em seis fases, das quais a preparação de dados é a que consome maior esforço na prática. Martínez-Plumed *et al.* (2021), ao revisitar o modelo duas décadas depois de sua formulação, oferecem uma crítica que interessa diretamente ao ensino: o CRISP-DM é apresentado como sequência de fases, mas projetos reais percorrem *trajetórias* — voltam à preparação depois de avaliar um modelo, revisam o entendimento do negócio depois de descobrir uma anomalia nos dados, reformulam a unidade de análise no meio do percurso. Os autores propõem substituir a leitura processual linear por uma leitura de trajetórias possíveis no espaço de atividades.

Esse deslocamento tem consequência pedagógica imediata. Se a preparação de dados fosse uma fase que se encerra, um laboratório poderia tratá-la como pré-requisito. Se ela é um ponto ao qual o projeto retorna repetidamente, então o laboratório precisa ser construído de modo que o retorno seja possível e barato — o que significa, concretamente, pipelines reexecutáveis, transformações versionadas e resultados intermediários inspecionáveis.

## 2.2 A tradição do data warehousing

Em paralelo, e com pouca interlocução, a área de bancos de dados desenvolveu o ETL como objeto próprio de pesquisa e de engenharia. Kimball e Caserta (2004) sistematizaram o trabalho de alimentação de um *data warehouse* em quatro grandes operações — extrair, limpar, conformar e entregar — e catalogaram os subsistemas necessários a cada uma. A palavra "conformar" merece destaque: designa a produção de dimensões e métricas com significado comum entre fontes que originalmente não o tinham. É o problema central de qualquer integração.

Vassiliadis (2009), em levantamento da tecnologia de ETL, organiza o campo em quatro frentes: modelagem conceitual e lógica dos fluxos, tratamento específico de cada uma das três etapas, questões transversais aos processos e protótipos de pesquisa. Ali e Wrembel (2017) atualizam o panorama e o estendem do projeto conceitual até a otimização de desempenho, mapeando problemas em aberto. O que essa literatura acrescenta à tradição do KDD é sobretudo uma sensibilidade de engenharia: o ETL é um artefato de software que precisa ser projetado, testado, mantido, monitorado e otimizado, e não um script descartável.

Kimball e Ross (2013) fornecem o vocabulário de modelagem do destino: tabelas-fato, dimensões, grão. O conceito de **grão** — a definição explícita do que representa uma linha da

tabela-fato — é, a meu ver, o conceito da tradição de data warehousing com maior valor formativo para a mineração de dados, e o menos aproveitado. Declarar o grão é exatamente a mesma operação que declarar a unidade de análise de um modelo preditivo. Um estudante que declara o grão antes de escrever a primeira consulta dificilmente produzirá, depois, uma tabela em que cada aluno aparece dezessete vezes porque a junção com matrículas multiplicou linhas.

### 2.3 Convergência, tensão e uma proposta de leitura

As duas tradições convergem nas operações e divergem na finalidade. O ETL clássico entrega um repositório estável, governado, compartilhado por muitos consumidores analíticos; sua métrica de sucesso é a consistência ao longo do tempo. O pré-processamento de KDD entrega um conjunto ajustado a uma pergunta e a um algoritmo; sua métrica de sucesso é o desempenho do modelo naquela tarefa. Um mesmo campo de data pode ser normalizado para o padrão ISO 8601 no primeiro caso e decomposto em dia da semana, mês e indicador de feriado no segundo.

Proponho a seguinte leitura articulada, que orienta o restante do texto: **o ETL é a camada em que se produzem os dados de que a análise dispõe; o pré-processamento é a camada em que se produzem os dados de que o algoritmo precisa.** A primeira é compartilhada e deve ser conservadora — preserva informação, documenta procedência, evita decisões irreversíveis. A segunda é específica e pode ser agressiva — descarta, agrega, discretiza, reescala, porque tem um destino declarado.

A distinção não é meramente terminológica. Ela fornece um critério prático para decidir onde uma transformação deve ocorrer, que é uma das dúvidas mais frequentes de quem começa: se a transformação perde informação e serve a um modelo específico, ela pertence ao pré-processamento e deve ficar fora do repositório; se ela normaliza representações sem perda e serve a qualquer consumidor, pertence ao ETL.

## 3 AS TRÊS OPERAÇÕES

### 3.1 Extração: o encontro com a heterogeneidade

Extrair é ler de sistemas que não foram projetados para serem lidos por você. A dificuldade raramente é a conexão; é a heterogeneidade. Santos e Dias (2025), em estudo da produção científica brasileira sobre integração de dados, identificam três grandes abordagens

— integração de sistemas e tecnologias, integração semântica e ontológica, e integração de dados heterogêneos em contextos aplicados — e observam um deslocamento do tratamento puramente técnico para perspectivas semânticas e contextualizadas, diante de desafios de heterogeneidade tecnológica, fragmentação e complexidade de padronização. A observação é pertinente: boa parte do que se chama de "problema de integração" não se resolve com conversores de formato.

Convém distinguir três níveis de heterogeneidade, que se apresentam simultaneamente em qualquer projeto realista:

a) **Heterogeneidade sintática** — formatos e codificações diferentes. Um CSV em latin-1 e com vírgula decimal, um JSON com estruturas aninhadas, uma tabela relacional. É o nível mais visível e o mais fácil de resolver.

b) **Heterogeneidade estrutural** — modelos de dados diferentes para a mesma entidade. O sistema A guarda endereço em um campo textual; o sistema B o decompõe em cinco colunas; o JSON da API o traz como objeto com chaves opcionais.

c) **Heterogeneidade semântica** — o mesmo rótulo designando coisas diferentes. "Aluno ativo" pode significar matriculado no semestre corrente em um sistema e sem trancamento formal em outro. Nenhuma ferramenta detecta essa divergência; ela exige interlocução com quem produz o dado.

O terceiro nível é o que justifica a recomendação, aparentemente burocrática, de documentar a procedência de cada campo extraído. Sem esse registro, a divergência semântica reaparece meses depois como um resultado inexplicável.

Do ponto de vista operacional, a decisão central da extração é entre carga completa e carga incremental. A carga completa relê tudo a cada execução: simples, custosa, sempre consistente. A incremental lê apenas o que mudou desde a última execução, o que exige um critério de mudança confiável — marca temporal de atualização, número de sequência ou registro de alterações do próprio SGBD. Kimball e Caserta (2004) tratam extensamente dos subsistemas de captura de mudanças, e a experiência docente sugere que este é o ponto em que estudantes descobrem, de forma produtiva, que "o sistema de origem não me dá o que eu preciso" é um problema de projeto, não um contratempo.

## 3.2 Transformação: a etapa epistemicamente densa

A transformação é onde se decide o que os dados significam. Han, Kamber e Pei (2011) organizam o pré-processamento em quatro famílias — limpeza, integração, redução e transformação — e o tratamento oferecido por García, Luengo e Herrera (2015) aprofunda cada uma delas com atenção aos efeitos sobre o aprendizado subsequente. Goldschmidt, Passos e Bezerra (2015) cobrem o mesmo terreno em língua portuguesa, articulando-o ao processo de KDD.

Sem repetir esses catálogos, destaco quatro decisões cuja natureza é conceitual antes de ser técnica.

**Primeira: o que é uma duplicata.** Dois registros com nomes grafados de modo diferente e mesma data de nascimento são a mesma pessoa? A resposta depende do custo relativo dos dois erros possíveis. Em um cadastro de beneficiários, fundir indevidamente dois indivíduos distintos produz dano maior do que manter dois registros de um mesmo indivíduo; em uma análise de comportamento de compra, o custo se inverte. Não existe regra de deduplicação correta em abstrato — existe regra adequada a uma consequência.

**Segunda: o que significa um valor ausente.** A distinção é clássica e continua mal ensinada. Um campo de data de conclusão vazio pode indicar que o dado não foi coletado, que o curso não foi concluído, ou que o sistema de origem usa uma data-sentinela para representar ausência. As três situações exigem tratamentos incompatíveis entre si, e a primeira providência não é imputar: é descobrir qual delas se aplica. Imputar a média de uma variável cuja ausência é informativa destrói justamente o sinal mais forte do conjunto.

**Terceira: qual é a unidade de análise.** É o problema do grão, transportado para o contexto preditivo. Uma tabela em que a linha é a matrícula e outra em que a linha é o aluno respondem a perguntas diferentes e não são intercambiáveis. A agregação que converte a primeira na segunda é uma escolha substantiva — média, último valor, contagem — e cada escolha carrega uma hipótese sobre o fenômeno.

**Quarta: quais transformações podem usar informação do conjunto inteiro.** Aqui está o erro mais custoso e menos visível. Kaufman, Rosset e Perlich (2012) formalizam o problema de vazamento de dados (*data leakage*) como a introdução, no conjunto de treinamento, de informação sobre o alvo que não estaria legitimamente disponível no momento da predição, e mostram que ele é causa recorrente de desempenhos irreprodutíveis em competições e em produção. Normalizar uma variável usando média e desvio calculados sobre todo o conjunto, antes da partição, é uma forma discreta e frequentíssima de vazamento. A

consequência didática é direta: a ordem entre partição e transformação não é detalhe de implementação; é condição de validade do resultado.

Essas quatro decisões têm algo em comum. Nenhuma delas é resolvida pela ferramenta, e todas são convidativas ao automatismo. É por isso que sustento que a transformação é a etapa epistemicamente densa do processo: ela é o lugar onde o julgamento do analista entra no conjunto de dados e permanece lá, invisível, até que alguém pergunte de onde veio aquele número.

### 3.3 Carga: fixar a estrutura do destino

Carregar é gravar o resultado em uma estrutura estável. As decisões relevantes são a modelagem do destino, o modo de atualização e o tratamento da história.

Sobre a modelagem, o esquema estrela descrito por Kimball e Ross (2013) — uma tabela-fato de grão declarado, cercada de dimensões descritivas — continua sendo a forma mais didática de tornar visível a diferença entre o que se mede e o que se descreve. Mesmo em um projeto de mineração cujo destino final seja um único arquivo tabular, passar pelo esquema estrela obriga o estudante a declarar o grão e a separar medidas de atributos, o que reduz drasticamente a incidência de tabelas mal formadas.

Sobre o modo de atualização, a distinção entre substituição integral, inserção incremental e atualização com reconciliação remete diretamente à decisão tomada na extração. E sobre a história, o tratamento de dimensões que mudam ao longo do tempo — o curso de um aluno, o cargo de um servidor — define se o repositório poderá responder a perguntas do tipo "qual era a situação no momento X". Sobrescrever é simples e apaga a história; versionar é mais caro e a preserva. Para análises preditivas que usam atributos históricos, sobrescrever é frequentemente fatal: produz vazamento, porque coloca no registro de um evento passado o valor de um atributo que só foi conhecido depois.

## 4 QUALIDADE DE DADOS: CRITÉRIO, NÃO ETAPA

É comum encontrar "qualidade de dados" listada como uma tarefa dentro do ETL, entre a extração e a carga. Argumento que essa localização é equivocada e que a qualidade deve ser tratada como critério transversal, avaliado em cada operação.

Batini *et al.* (2009) sistematizam e comparam metodologias de avaliação e melhoria de qualidade de dados, organizando o campo em torno de dimensões mensuráveis e de

procedimentos de diagnóstico e intervenção. Ehrlinger e Wöß (2022), examinando ferramentas de medição e monitoramento, encontram um descompasso significativo: as dimensões consolidadas na pesquisa — acurácia, completude, consistência e atualidade — não se traduzem em conjuntos abrangentes de métricas nas ferramentas disponíveis, e o monitoramento contínuo costuma estar restrito a versões comerciais. A conclusão das autoras é sóbria e útil ao ensino: não se pode terceirizar à ferramenta a definição do que conta como qualidade em um dado contexto.

A razão para tratar qualidade como critério transversal é que cada operação do pipeline pode degradá-la. Uma extração incremental com critério de mudança frouxo compromete a completude. Uma regra de deduplicação agressiva compromete a acurácia. Uma carga que sobrescreve compromete a atualidade histórica. Verificar qualidade apenas ao final significa descobrir o problema sem saber onde ele foi introduzido.

A evidência mais contundente sobre o custo de negligenciar esse ponto vem de Sambasivan *et al.* (2021). Em estudo com 53 profissionais de inteligência artificial na Índia, na África Oriental, na África Ocidental e nos Estados Unidos, os autores identificam o que chamam de *data cascades*: problemas de qualidade que se propagam e se agravam ao longo do ciclo do projeto, presentes na grande maioria dos casos examinados e tipicamente invisíveis até que seus efeitos se manifestem a jusante. Os autores associam o fenômeno à desvalorização sistemática do trabalho com dados frente ao trabalho com modelos. Whang *et al.* (2023), revisando desafios de coleta e qualidade de dados sob a perspectiva da inteligência artificial centrada em dados, reforçam a mesma direção a partir da literatura técnica.

Para uma disciplina de mineração de dados, esse conjunto de achados sustenta uma inversão de ênfase que considero justificada: dedicar ao trabalho com dados uma fração do tempo letivo proporcional à fração do esforço que ele consome em projetos reais.

## 5 UMA OBJEÇÃO SÉRIA: O ETL ESTARIA SUPERADO?

O argumento deste texto precisa enfrentar uma posição contrária consistente, hoje dominante no discurso da indústria. Segundo ela, o ETL seria um artefato da era em que armazenamento e processamento eram caros; com armazenamento barato e processamento elástico, a ordem racional passaria a ser ELT — carregar os dados brutos primeiro e transformá-los sob demanda, no próprio repositório.

A posição tem fundamento técnico real. Armbrust *et al.* (2021) apresentam a arquitetura de *lakehouse* como plataforma aberta que unifica, sobre formatos de arquivo abertos, funções antes separadas entre data warehouse e data lake, oferecendo gestão de metadados e transações sobre dados brutos. Wrembel (2023), em análise da evolução das arquiteturas de integração de dados, descreve uma trajetória que vai de arquiteturas de integração virtual para arquiteturas de integração física e, mais recentemente, para arquiteturas que sustentam ambas, e aponta como direções de pesquisa a flexibilidade da integração, a garantia de qualidade em sistemas multimodais complexos e a otimização da execução dos processos de integração.

Reconhecida a validade dessa evolução, sustento que ela não desloca a tese aqui defendida, por três razões.

A primeira é que o ELT **altera a ordem das operações, não sua natureza**. Deduplicar, conformar semanticamente, declarar grão e tratar ausências continuam sendo necessários; passam a ocorrer depois da carga, dentro do repositório, frequentemente em SQL. O conjunto de decisões conceituais descrito na seção 3.2 permanece integralmente.

A segunda é que o adiamento da transformação **transfere o risco, não o elimina**. Quando cada consumidor transforma os dados brutos por conta própria, a conformação semântica deixa de ser feita uma vez e passa a ser refeita muitas vezes, com resultados divergentes. É precisamente o problema que a conformação de dimensões resolvia (KIMBALL; CASERTA, 2004). As arquiteturas contemporâneas respondem a isso com camadas de transformação governadas dentro do próprio repositório — o que é, em substância, ETL executado depois da carga.

A terceira razão é didática. Mesmo que o ELT fosse superior em todos os cenários de produção, o ETL continuaria sendo o melhor dispositivo de ensino, porque **torna as decisões explícitas e localizáveis**. Em um pipeline ETL, a regra de deduplicação está em um ponto identificável, com entrada e saída inspecionáveis. Em um ambiente ELT maduro, a mesma regra está distribuída entre modelos SQL encadeados, o que é eficiente para quem já domina o conceito e opaco para quem está aprendendo a formá-lo.

Há ainda uma objeção de outra ordem, mais próxima da prática docente: a de que usar dados sujos em sala consome tempo que seria melhor empregado em algoritmos. O contra-argumento está nos achados de Sambasivan *et al.* (2021) e de Kaufman, Rosset e Perlich (2012). Um estudante que domina algoritmos e não domina preparação produz modelos cujo

desempenho aparente não se sustenta — e, o que é pior, não dispõe dos conceitos necessários para descobrir por quê.

## 6 IMPLICAÇÕES DIDÁTICAS: PRINCÍPIOS PARA UM LABORATÓRIO DE ETL

Do argumento desenvolvido decorrem sete princípios de desenho, que registro aqui como ponte para a atividade prática.

**1. Heterogeneidade real, nos três níveis.** Um laboratório com três arquivos CSV bem formados exercita apenas sintaxe. As fontes devem diferir em formato (CSV, JSON, tabelas relacionais em SGBDs distintos), em estrutura (mesma entidade modelada de modos diferentes) e em semântica (mesmo rótulo com significados divergentes). O terceiro nível é o que produz a aprendizagem mais durável, porque não se resolve por consulta à documentação da ferramenta.

**2. Volume que impeça a inspeção manual.** Enquanto o conjunto couber na tela, o estudante corrigirá anomalias uma a uma. A partir de uma ordem de grandeza de centenas de milhares de registros, a correção precisa ser formulada como regra — e formular a regra é o objetivo de aprendizagem.

**3. Ambiguidade deliberada, sem resposta única.** Ao menos uma decisão de transformação deve ser genuinamente indecidível a partir dos dados, exigindo que o estudante adote um critério, o registre e justifique suas consequências. É o que transforma a atividade de execução em investigação.

**4. Isolamento e reprodutibilidade por contêiner.** O uso de Docker aqui não é modismo: um ambiente declarado em arquivo garante que todos os estudantes enfrentem exatamente o mesmo problema, elimina a variabilidade de instalação local e permite reiniciar o cenário do zero quantas vezes forem necessárias. A reexecutabilidade do pipeline é, além disso, o pré-requisito técnico da leitura em trajetórias proposta por Martínez-Plumed *et al.* (2021): só é possível retornar à preparação se retornar for barato.

**5. Grão declarado antes da primeira consulta.** Exigir que a especificação da tabela-fato preceda a escrita de código previne a classe mais comum de erro estrutural e materializa o conceito de unidade de análise (KIMBALL; ROSS, 2013).

**6. Verificações de qualidade ao longo do pipeline, não ao final.** Cada etapa deve produzir uma contagem verificável e ao menos uma asserção explícita — cardinalidade esperada após junção, domínio admissível de um campo, ausência de chaves órfãs. Isso operacionaliza, em escala de laboratório, o que Ehrlinger e Wöß (2022) descrevem como monitoramento de qualidade.

**7. Partição antes de qualquer transformação dependente do conjunto.** O roteiro deve conter um ponto em que o vazamento ocorreria naturalmente se a ordem não fosse controlada, de modo que o estudante o produza, meça seu efeito e o corrija (KAUFMAN; ROSSET; PERLICH, 2012).

A escolha do Orange como ambiente de mineração ao final do pipeline é coerente com esse desenho. A ferramenta, descrita por Demšar *et al.* (2013) como uma caixa de ferramentas de mineração de dados baseada em componentes com programação visual, separa visualmente o fluxo de dados das operações de modelagem — o que permite ao estudante ver, no próprio grafo do fluxo, a fronteira entre o que foi decidido no ETL e o que está sendo decidido no modelo. Essa visibilidade é exatamente o que a seção 5 defendeu como vantagem didática do ETL sobre o ELT.

Vale registrar, por fim, que o contexto brasileiro oferece campo empírico abundante para atividades desse tipo. A revisão de Colpo *et al.* (2024) sobre mineração de dados educacionais aplicada à predição da evasão estudantil mapeia tendências, oportunidades e desafios de uma área em que as fontes são, por natureza, múltiplas e heterogêneas — dados acadêmicos, demográficos e econômicos provenientes de sistemas distintos. Um laboratório de ETL ancorado em dados educacionais tem, portanto, correspondência direta com uma agenda de pesquisa ativa no país.

## 7 LIMITES DESTE REFERENCIAL

A honestidade sobre o alcance do que foi argumentado é parte do argumento.

**Limite de escopo metodológico.** Este é um referencial teórico construído por seleção argumentativa, não uma revisão sistemática. Não houve protocolo de busca exaustivo, critérios de inclusão formalizados nem avaliação de risco de viés. As obras foram escolhidas por sua função na linha argumentativa e por serem verificáveis; outras escolhas produziriam ênfases diferentes.

**Limite linguístico.** A literatura primária sobre ETL e sobre modelagem de fluxos de transformação é predominantemente anglófona, e não foi localizado, em periódicos brasileiros com avaliação por pares, tratamento equivalente do tema em língua portuguesa. As fontes em inglês foram utilizadas por essa razão, e não por preferência. As contribuições em português aqui mobilizadas (GOLDSCHMIDT; PASSOS; BEZERRA, 2015; COLPO *et al.*, 2024; SANTOS; DIAS, 2025) cobrem o processo de KDD, a mineração de dados educacionais e a integração de dados, respectivamente, mas não o ETL como objeto de engenharia.

**Limite temporal e tecnológico.** Parte da literatura estrutural mobilizada — Fayyad *et al.* (1996), Kimball e Caserta (2004), Vassiliadis (2009) — antecede em muito o recorte de oito anos normalmente adotado para artigos. Foi mantida por seu caráter fundacional e por ainda organizar o vocabulário do campo; sempre que possível, foi confrontada com literatura recente (ALI; WREMBEL, 2017; ARMBRUST *et al.*, 2021; WHANG *et al.*, 2023; WREMBEL, 2023).

**Limite de recorte técnico.** O texto trata de ETL em lote sobre dados estruturados e semiestruturados. Não aborda processamento de fluxo contínuo, dados não estruturados em larga escala, nem arquiteturas distribuídas de transformação — temas legítimos que exigiriam outro referencial.

**Limite de generalização didática.** Os princípios da seção 6 derivam de um argumento teórico e da prática docente em um contexto específico: ensino superior de computação, com turma que domina previamente SQL e programação. Não foram submetidos a avaliação empírica controlada. Constituem hipóteses de desenho, e sua eficácia relativa permanece uma questão aberta.

## 8 CONSIDERAÇÕES FINAIS

Retomo a pergunta inicial. O que se perde ao ensinar ETL e pré-processamento separadamente é a compreensão de que ambos são o mesmo trabalho visto de dois pontos: o da infraestrutura que torna os dados disponíveis e o da análise que os torna adequados. O que se ganha ao articulá-los é um critério para decidir onde cada transformação deve viver — e, com ele, a capacidade de justificar escolhas que de outro modo permaneceriam implícitas.

O argumento central deste referencial é que a transformação é o lugar onde o julgamento do analista se inscreve nos dados de forma duradoura. Regras de duplicação, tratamentos de ausência, definições de granularidade e ordenações entre partição e normalização não são detalhes de implementação: são as condições de validade de tudo o que vem depois. Ensinar mineração de dados sem ensinar isso é ensinar a operar um instrumento sem ensinar a calibrá-lo.

Desse argumento decorrem implicações que ultrapassam o desenho de um laboratório. Para a **formação**, sugere-se rever a proporção entre tempo dedicado a algoritmos e tempo dedicado a dados, aproximando-a da proporção observada em projetos reais. Para a **avaliação**, sugere-se que os produtos de aprendizagem incluam a justificativa documentada das decisões de transformação, e não apenas a métrica final do modelo — um pipeline com decisões bem fundamentadas e acurácia modesta demonstra mais aprendizagem do que o inverso. Para a **pesquisa**, permanecem em aberto duas questões que este texto apenas formula: como se desenvolve, em estudantes, a competência de reconhecer que um problema de dados é um problema conceitual; e se a exposição deliberada a ambiguidade irredutível acelera ou obstrui esse desenvolvimento.

Há, por fim, uma dimensão que o recorte técnico deste texto não comportou, mas que registro como direção futura. Quando se decide o que conta como duplicata, o que significa uma ausência e qual é a unidade de análise, decide-se também quem fica visível no conjunto de dados e quem desaparece nele. Em aplicações educacionais — predição de evasão, alocação de apoio pedagógico — essas decisões têm consequências sobre sujeitos concretos. Tratar a transformação como operação técnica neutra é, também por essa razão, um equívoco que a formação deveria corrigir cedo.

## REFERÊNCIAS


ALI, Syed Muhammad Fawad; WREMBEL, Robert. From conceptual design to performance optimization of ETL workflows: current state of research and open problems. **The VLDB Journal**, v. 26, n. 6, p. 777-801, 2017. DOI: 10.1007/s00778-017-0477-2.

ARMBRUST, Michael; GHODSI, Ali; XIN, Reynold; ZAHARIA, Matei. Lakehouse: a new generation of open platforms that unify data warehousing and advanced analytics. In: CONFERENCE ON INNOVATIVE DATA SYSTEMS RESEARCH (CIDR), 11., 2021. **Proceedings** [...]. [S. l.: s. n.], 2021.

BATINI, Carlo; CAPPIELLO, Cinzia; FRANCALANCI, Chiara; MAURINO, Andrea. Methodologies for data quality assessment and improvement. **ACM Computing Surveys**, v. 41, n. 3, art. 16, 2009. DOI: 10.1145/1541880.1541883.

COLPO, Miriam Pizzatto; PRIMO, Tiago Thompsen; AGUIAR, Marilton Sanchotene de; CECHINEL, Cristian. Mineração de dados educacionais na predição da evasão estudantil: tendências, oportunidades e desafios. **Revista Brasileira de Informática na Educação**, v. 32, p. 220-256, 2024. DOI: 10.5753/rbie.2024.3559.

DEMŠAR, Janez *et al.* Orange: data mining toolbox in Python. **Journal of Machine Learning Research**, v. 14, p. 2349-2353, 2013.

EHRLINGER, Lisa; WÖSS, Wolfram. A survey of data quality measurement and monitoring tools. **Frontiers in Big Data**, v. 5, art. 850611, 2022. DOI: 10.3389/fdata.2022.850611.

FAYYAD, Usama; PIATETSKY-SHAPIRO, Gregory; SMYTH, Padhraic. From data mining to knowledge discovery in databases. **AI Magazine**, v. 17, n. 3, p. 37-54, 1996. DOI: 10.1609/aimag.v17i3.1230.

GARCÍA, Salvador; LUENGO, Julián; HERRERA, Francisco. **Data preprocessing in data mining**. Cham: Springer, 2015. (Intelligent Systems Reference Library, v. 72). ISBN 978-3-319-10246-7.

GOLDSCHMIDT, Ronaldo; PASSOS, Emmanuel; BEZERRA, Eduardo. **Data mining**: conceitos, técnicas, algoritmos, orientações e aplicações. 2. ed. Rio de Janeiro: Elsevier, 2015. ISBN 978-85-352-7822-4.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. **Data mining**: concepts and techniques. 3. ed. Waltham: Morgan Kaufmann, 2011. ISBN 978-0-12-381479-1.

KAUFMAN, Shachar; ROSSET, Saharon; PERLICH, Claudia. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, art. 15, 2012. DOI: 10.1145/2382577.2382579.

KIMBALL, Ralph; CASERTA, Joe. **The data warehouse ETL toolkit**: practical techniques for extracting, cleaning, conforming, and delivering data. Indianapolis: Wiley, 2004. ISBN 978-0-7645-6757-5.

KIMBALL, Ralph; ROSS, Margy. **The data warehouse toolkit**: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013. ISBN 978-1-118-53080-1.

MARTÍNEZ-PLUMED, Fernando *et al.* CRISP-DM twenty years later: from data mining processes to data science trajectories. **IEEE Transactions on Knowledge and Data Engineering**, v. 33, n. 8, p. 3048-3061, 2021. DOI: 10.1109/TKDE.2019.2962680.

SAMBASIVAN, Nithya *et al.* "Everyone wants to do the model work, not the data work": data cascades in high-stakes AI. In: CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2021, Yokohama. **Proceedings** [...]. New York: ACM, 2021. DOI: 10.1145/3411764.3445518.

SANTOS, Sarah Rúbia de Oliveira; DIAS, Célia da Consolação. Panorama das abordagens de integração de dados: um estudo da produção científica brasileira em Ciência da Informação. **Brazilian Journal of Information Science: research trends**, v. 19, p. e025012, 2025. DOI: 10.36311/1981-1640.2025.v19.e025012.

VASSILIADIS, Panos. A survey of extract-transform-load technology. **International Journal of Data Warehousing and Mining**, v. 5, n. 3, p. 1-27, 2009. DOI: 10.4018/jdwm.2009070101.

WHANG, Steven Euijong; ROH, Yuji; SONG, Hwanjun; LEE, Jae-Gil. Data collection and quality challenges in deep learning: a data-centric AI perspective. **The VLDB Journal**, v. 32, n. 4, p. 791-813, 2023. DOI: 10.1007/s00778-022-00775-9.

WREMBEL, Robert. Data integration revitalized: from data warehouse through data lake to data mesh. In: DATABASE AND EXPERT SYSTEMS APPLICATIONS (DEXA 2023), 2023. **Proceedings** [...]. Cham: Springer, 2023. p. 3-18. (Lecture Notes in Computer Science, v. 14146). DOI: 10.1007/978-3-031-39847-6_1.