PROJETO PRÁTICO DE ETL: MERCATTO VAREJO

Relatório Técnico de Diagnóstico e Perfilamento de Fontes Heterogêneas (Semana 1)

Equipe: Lorena Strobel Campos (2023278440028) & Mateus de Souza Arruda (2023278440030)

INTRODUÇÃO E FORMULAÇÃO DO PROBLEMA DE NEGÓCIO

Conforme postulado no referencial teórico da disciplina (ETL como preparação de dados na mineração de dados: fundamentos, decisões e implicações didáticas), a engenharia de ETL não constitui mera rotina instrumental ou neutra, mas a infraestrutura epistêmica na qual julgamentos analíticos são inscritos nos dados de forma irreversível. A ausência de perfilamento rigoroso gera cascatas de dados, nas quais vícios conceituais das origens propagam-se silenciosamente até o modelo de aprendizado de máquina.

No contexto da Mercatto Varejo, a aquisição da Commerce Br resultou na coexistência de quatro fontes de dados independentes somando cerca de 2,2 milhões de registros: o ERP Legado em MySQL, a plataforma digital de E-commerce em PostgreSQL, o repositório de Atendimentos do SAC em arquivo CSV e as Avaliações de Marketplace em formato NDJSON. O objetivo estratégico da organização consiste em responder à seguinte pergunta formal de negócio:

> **Pergunta de Negócio (Janela Preditiva):** *Dado o comportamento histórico e o padrão de compras do cliente até 30 de junho de 2025, ele realizará ao menos uma nova compra válida entre 1º de julho e 28 de setembro de 2025?*

a) Quais campos são candidatos a chave de junção entre as fontes? Qual a cobertura real de cada candidato, em número absoluto e percentual?

Para cada candidato foram verificadas correspondências e cobertura em relação aos registros de origem.

O **CPF** foi considerado como um candidato devido a identificação dos clientes de maneira única tanto no sistema legado quanto no *e-commerce* através dos campos CLIENTES.cpf e customer.tax_id. Do legado para o *e-commerce*, 13.048 registros encontraram correspondência entre os 47.250 do legado, correspondendo a 27,61% dos 47.250 registros. Considerando os registros com CPF preenchido, a cobertura foi de 30,47% dos 42.287. Já do *e-commerce*, para o legado, foram 12.606 entre os 85.000 clientes, equivalente a 14,83% da base total e 16,13% dos 78.145 registros com “tax_id” preenchida. Tais resultados indicam a existência de CPFs repetidos.

Para relacionar os atendimentos do SAC aos pedidos, foi considerado “origem_sistema” e “id_pedido_origem”, nesse caso houve 100% nas duas, com 36.527 nos atendimentos a pedidos no legado e 59.613 a pedidos do e-commerce.

No arquivo *JSON* de avaliações do *marketplace* (avaliacoes_marketplace.json), o campo de order.ref, utilizado para relacionar as avaliações dos pedidos identificando a origem de referência, teve correspondência de 40.016 avaliações de pedido do legado e 119.984 avaliações do *e-commerce*, o que resulta em 100% de cobertura nas fontes. As avaliações aos produtos e as referências de produto, product.sku, apresentaram cobertura de 100% nas comparações.

Foi observado que a cobertura varia conforme o campo que é utilizado. O CPF por exemplo, ainda que possua muitas correspondências, não permite associar todos os cadastros de clientes entre os sistemas. Dessa maneira, a escolha das chaves de junção deve considerar tanto a cobertura observada quanto às limitações dos identificadores, evitando associações incorretas ou perdas de registros.

b) Onde há heterogeneidade semântica — o mesmo rótulo com significados diferentes entre sistemas? Apresente ao menos três casos, cada um com evidência numérica.

Os campos referentes a ***Status*** possuem diferenças no sistema legado e no sistema de *e-commerce*, um exemplo é que "entregue" possui 101.192 enquanto "*delivered*" no *e-commerce* possui 207.204. Além da diferença na quantidade de registros, há a presença de conjuntos distintos, no legado há quatro *status*, enquanto no *e-commerce* existem 5 categorias para *status*, inclusive o de "payment_declined" referente à recusa de pagamento. Dessa forma, a diferença mostra que não há correspondência direta e não é possível confirmar a equivalência dos campos entre os sistemas.

Em **produtos**, no legado existem 23 categorias não vazias entre os 3.000 produtos, além de 103 valores vazios. Já no *e-commerce* existem 21 categorias onde somente 15 estão associadas a produtos. Essas diferenças evidenciam classificações com níveis distintos; há também discrepâncias em relação à escrita e possíveis sobreposições entre as categorias.

Nos canais de vendas, o campo **CANAL** do sistema legado apresenta campos como LOJA, SITE e TELEVENDAS entre os 130.000 pedidos. No *e-commerce* o campo "*channel*" possui 200.000 prédios, já avaliações do marketplace no *JSON* de avaliações o "order.channel" era de 160.000 registros de avaliação. Essas divergências mostram que os sistemas adotam formas distintas de classificação, da qual seria necessário uma conferência, por exemplo, se o canal de TELEVENDAS possui equivalência entre os canais do e-commerce.

Esses casos mostram que a heterogeneidade semântica ocorre quando várias fontes estão envolvidas, pois representam informações semelhantes com classificações, níveis de detalhamento e significados que se diferem. Para a integração dos dados futuramente é necessário padronizar os nomes, textos e seu significado para estabelecer correspondências adequadas.

c) `VALOR_TOTAL` no legado e `total_amount` no e-commerce medem a mesma coisa? Prove sua resposta reconciliando cada um com a soma dos itens do pedido.

No dicionário de dados da organização, foi deixada a advertência de um analista em 2021: 'cuidado com o `VALOR_TOTAL`, não é o que parece'. Para elucidar essa questão, procedeu-se à reconciliação contábil exaustiva entre os totais informados nos cabeçalhos dos pedidos e a somatória de suas respectivas linhas de itens:

$$Soma_Itens = \Sigma\ (VL_UNITARIO_i \times QTD_i - VL_DESCONTO_i)$$

Comparando individualmente cada pedido contra a soma dos seus itens sob tolerância estrita de R$ 0,02 (para mitigar eventuais arredondamentos de ponto flutuante), obtiveram-se os resultados comprovados na tabela abaixo:

Sistema / Atributo Avaliado	Volume Total de Pedidos	Bate c/ Soma dos Itens + Frete	Bate c/ Soma dos Itens (Sem Frete)	Semântica Verdadeira Comprovada
ERP Legado `VALOR_TOTAL`	130.000	**130.000 (100,0%)**	24 (0,018%)*	**Valor Bruto com Frete Incluso**
E-commerce `total_amount`	280.000	0 (0,0%)	**280.000 (100,0%)**	**Valor Líquido dos Produtos (Sem Frete)**

** Os 24 pedidos do legado que batem sem frete correspondem exclusivamente a transações com frete zerado (`VALOR_FRETE = 0,00`).*

A prova analítica definitiva emerge da subtração vetorial entre o total do pedido e a soma dos seus itens:

No **ERP Legado:** `VALOR_TOTAL − Soma_Itens = VALOR_FRETE` em exatamente 100% dos 130.000 pedidos. O atributo registra o custo total desembolsado pelo cliente final, incorporando a tarifa logística.

Na **Commerce Br:** `total_amount − Soma_Itens = 0,00` em exatamente 100% dos 280.000 pedidos. A cobrança de frete é segregada no atributo `freight_amount` e nunca é somada ao cabeçalho.

Implicação Crítica para o Data Warehouse: `VALOR_TOTAL` e `total_amount` não medem a mesma grandeza contábil. Caso fossem carregados para o mesmo campo dimensional sem conformação, o faturamento das lojas físicas seria superestimado em relação ao e-commerce em exatamente o montante do frete.

d) Quais anomalias você consegue quantificar agora, e quais só aparecerão depois da integração? Por quê?

A teoria de qualidade de dados ensina que a detecção de defeitos é condicionada pelo escopo das relações disponíveis. São inconsistências de domínio, sintaxe ou integridade intra registro, detectadas em uma única tabela sem cruzar com outras entidades:

• **Valores Sentinela:** Data de entrega `DT_ENTREGA = '1900-01-01'` no legado (1.025 pedidos no perfil; ~1.284 no total, 0,99% dos pedidos entregues); `CIDADE = 'N/A'` (2,0% dos clientes legados); `VL_DESCONTO = -1` (1,0% dos itens).

• **Violações de Limites Físicos:** Frete negativo em pedidos (362 no legado; 612 no e-commerce); tempo de resolução negativo no SAC (0,4% dos registros).

• **Anacronismos Temporais:** Data de entrega anterior à data do pedido (`DT_ENTREGA < DT_PEDIDO`) em 0,8% dos pedidos entregues.

• **Vícios de Codificação e Formato:** Arquivos em *latin-1* (100% no SAC e Legado); 1.377 registros de SAC com quebra de linha dentro do campo textual de motivo; 1.140 linhas duplicadas idênticas no CSV do SAC.

• **Esquema Irregular:** No *Marketplace NDJSON*, o atributo *rating* oscila entre inteiro (139.061) e *string* (16.108), além de 4.831 valores nulos (3,0%); omissão de chaves opcionais (`helpful_votes` omitido em 45,1%).

Para as **Anomalias Observáveis** somente após a integração relacional, são defeitos que dependem da relação entre múltiplas tabelas ou da harmonização de conceitos:

• **Chaves Órfãs (Quebra de Integridade Referencial):** Linhas em `ITENS_PEDIDO` e `order_item` cujo identificador de pedido não existe na tabela de pedidos (atinge ~1,5% dos itens em ambas as origens). É invisível ao consultar apenas a tabela de itens.

• **Conflitos de Identidade Multissistema:** Clientes com mesmo CPF em ambos os sistemas mas com nomes grafados com divergências ou cidades diferentes; sobreposição

parcial de 15,1% que não possui CPF em um dos lados.

• **Desconexão de Eventos Auxiliares:** Atendimentos de SAC e avaliações que apontam para pedidos expurgados ou inexistentes.

• **Desalinhamento Temporal:** Junção de transações noturnas afetadas por fusos horários divergentes (UTC vs. local), deslocando o pedido entre dias fiscais distintos.

e) Qual é o grão pretendido de cada tabela-fato? Escreva a frase completa no padrão formal.

A declaração do grão define a unidade atômica indiscutível de cada fato dimensional. Para evitar ambiguidades estruturais, veda-se o uso de conjunções aditivas ('e também'):

Declaração de Grão — Fato Pedido (`dw.fato_pedido`):
'Uma linha de `dw.fato_pedido` representa a emissão e fechamento de um pedido comercial único, transacionado por um cliente em um canal de venda específico e em um determinado ponto no tempo.'

Declaração de Grão — Fato Item de Pedido (`dw.fato_item_pedido`):
'Uma linha de `dw.fato_item_pedido` representa a venda individual de uma linha de produto associada a um pedido comercial, registrando a quantidade comercializada, o preço unitário praticado e o desconto concedido.'