INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE MATO GROSSO
DEPARTAMENTO DE COMPUTAÇÃO · BACHARELADO EM ENGENHARIA DE COMPUTAÇÃO
DISCIPLINA DE MINERAÇÃO DE DADOS (2026/2) — PROF. DR. ORLANDO JÚNIOR

RELATÓRIO DE RESULTADOS DO EXPERIMENTO DE VAZAMENTO (SEMANA 4)

Avaliação Empírica da ABT de Recompra (90 Dias) e Diagnóstico de Data Leakage no Orange Data Mining

Dupla: Mateus de Souza Arruda & Lorena Strobel Campos

1. PROTOCOLO EXPERIMENTAL E CONSTRUÇÃO DAS DUAS VERSÕES DA ABT

Em conformidade com o Sétimo Princípio do referencial teórico da disciplina e com a taxonomia de Kaufman et al. (2012), a tabela analítica foi materializada no esquema `abt` no grão atômico de **uma linha por cliente real que realizou ao menos um pedido até a data de corte de 30/06/2025** (`cliente_sk <> -1`, excluindo o registro sentinela de pedidos órfãos do RDT-12). O universo resultante compreende exatamente **99.749 clientes únicos**, dos quais **21.711 (21,7656%)** realizaram ao menos uma compra válida (status diferente de `CANCELADO`) na janela preditiva de 90 dias (`01/07/2025` a `28/09/2025`), e **78.038 (78,2344%)** não recompraram.

No script `etl/04_abt.py`, a versão íntegra (`abt.recompra_90d`, RDT-14, homologada com 19/19 asserções em `Suite('04_abt_correta')`) aplica trava temporal dupla (`<= 2025-06-30`) tanto sobre os pedidos quanto sobre os eventos de entrega, SAC e avaliações, expurgando 13.115 protocolos de SAC e 20.232 avaliações posteriores ao corte, e preserva `NaN` nas médias condicionais (`prazo_medio_entrega` com 7.088 ausentes; `nota_media_avaliacoes` com 42.974 ausentes). Em contrapartida, a versão com vazamento (`abt.recompra_90d_vazamento`, RDT-15, 21/21 asserções) injeta dois defeitos deliberados: **(1) Vazamento Temporal Direto:** supressão do predicado `data_pedido_sk <= '2025-06-30'`, contaminando 100% da amostra auditada (1.000/1.000 clientes) e produzindo `recencia_dias < 0` (entre -1 e -184 dias, média de -72,39 dias nos recompradores) para **43.434 clientes (43,54%)**; e **(2) Vazamento Estatístico Pré-Split:** padronização Z-Score global sobre `valor_monetario_total` antes da divisão treino/teste, gerando média 0,03, desvio 1,00 e **56.381 valores negativos**.

Ambas as tabelas foram exportadas por `etl/05_exportar_orange.py` com cabeçalho nativo de três linhas (definindo `alvo_recompra_90d` como `class` e `cliente_sk`/`data_corte` como `meta`) e submetidas a topologia idêntica nos fluxos `orange/fluxo_recompra_correta.ows` e `orange/fluxo_recompra_vazamento.ows`: amostragem estratificada **70% treino (69.825 clientes)** / **30% teste (29.924 clientes: 23.412 negativos e 6.512/6.513 positivos)** com semente fixa e avaliação estrita na partição retida (*Test on test data*).

2. QUESTÃO a) COMPARAÇÃO DE AUC E ACURÁCIA BALANCEADA ENTRE AS VERSÕES

Pergunta a) (Seção 5 do Enunciado): *Qual a diferença de AUC e de acurácia balanceada entre as duas versões da ABT nos três modelos? Apresente os números lado a lado.*

Modelo	Versão da ABT	AUC-ROC	Delta AUC	Acurácia Balanceada	Delta BalAcc	CA / Rec(p)	F1 (Pond.)	Prec. (Pond.)	MCC	F1 / Rec (Alvo=1)
Naive Bayes	Correta (RDT-14)	0,5367	—	0,5040	—	0,7811	0,6914	0,7023	0,0391	0,0256 / 0,0132
Naive Bayes	**Vazamento (RDT-15)**	**0,8888 (0,887)**	**+0,3521**	**0,7896**	**+0,2856**	0,8074 (0,805)	0,8178 (0,816)	0,8408 (0,840)	0,5191 (0,515)	0,6314 / 0,7579
Reg. Logística	Correta (RDT-14)	0,5137	—	0,5000	—	0,7823	0,6868	0,6121	0,0000	0,0000 / 0,0000
Reg. Logística	**Vazamento (RDT-15)**	**0,8033 (0,804)**	**+0,2896**	**0,5516**	**+0,0516**	0,7601 (0,755)	0,7248 (0,721)	0,7124 (0,707)	0,1409 (0,128)	0,2487 / 0,1824
Tree (Árvore)	Correta (RDT-14)	0,5045	—	0,5068	—	0,7026	0,6812	0,6649	0,0157	0,1897 / 0,1600
Tree (Árvore)	**Vazamento (RDT-15)**	**0,8796 (0,861)**	**+0,3751**	**0,8462**	**+0,3394**	0,9024 (0,899)	0,9013 (0,898)	0,9007 (0,897)	0,7078 (0,699)	0,7691 / 0,7467

Tabela 1: *Comparação pareada no Orange Test & Score (N = 29.924; entre parênteses, a visão Average over classes de 3 casas decimais). A Acurácia Balanceada é definida por BalAcc = (Recall_1 + Especificidade_0) / 2.*

Análise Crítica da Questão a) (Origem do Sinal Real): Na **ABT Correta**, os modelos convergem para AUC entre **0,5045 e 0,5367** e Acurácia Balanceada entre **0,5000 e 0,5068**. Isso reflete fielmente o processo gerador (`gerador/gerar_dados.py`): dentro de cada sistema isolado, os pedidos seguem um sorteio de Poisson homogêneo sem memória (`rng.integers(1, N_CLI + 1)`). O único sinal preditivo legítimo provém da unificação omnicanal por CPF (RDT-02): os **12.539 clientes presentes em ambos os sistemas** (`AMBOS`) recebem sorteios duplos de compras, exibindo taxa real de recompra de **35,26%** no alvo contra **20,71%** no e-commerce exclusivo e **17,74%** no legado exclusivo (capturado por `propensao_online` e `frequencia_pedidos`).

2.1. Evidências Visuais do Experimento: Curvas ROC e Matrizes de Confusão

Sob desbalanceamento (78,23% de classe 0), a Acurácia Global (CA) de **0,7823** e o F1 ponderado de **0,6868** na Regressão Logística são ilusórios (classificador majoritário degenerado com Recall na classe 1 = 0,0000, MCC = 0,0000 e BalAcc = 0,5000). Com a introdução do vazamento, o salto artificial nas 29.924 instâncias de teste é massivo (Figura 1): a **Árvore de Decisão** eleva sua AUC em **+0,3751** (de 0,5045 para **0,8796** / 0,861) e sua Acurácia Balanceada em **+0,3394** (para **0,8462**, com CA = 0,9024 e MCC = 0,7078); o **Naive Bayes** ganha **+0,3521 de AUC** (para **0,8888** / 0,887) e **+0,2856 de BalAcc** (para **0,7896**, com CA = 0,8074 e MCC = 0,5191); e a **Regressão Logística** salta **+0,2896 em AUC** (para **0,8033** / 0,804), mas apenas **+0,0516 em BalAcc** (para **0,5516**, com MCC = 0,1409).

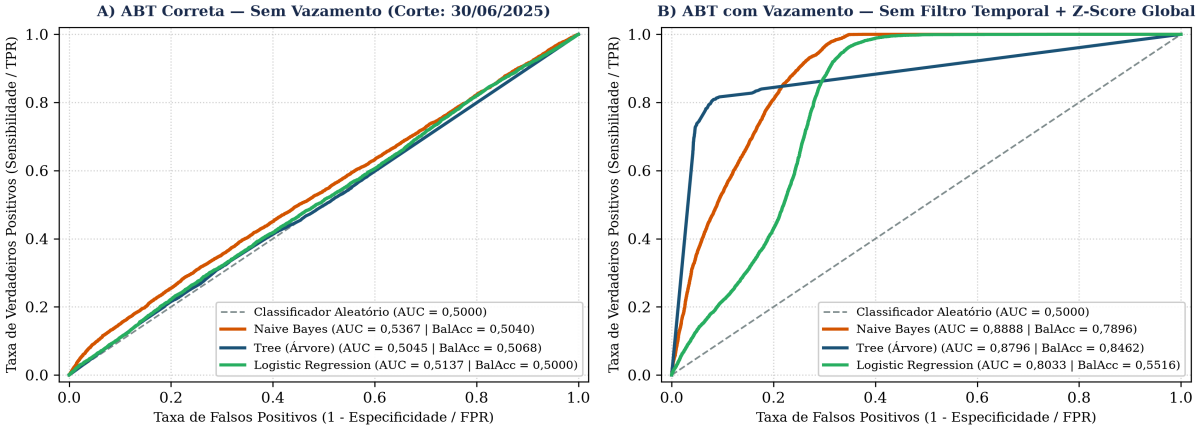


Figura 1: *Curvas ROC comparativas nativas do Orange na partição de teste (N = 29.924). Esquerda (A): ABT Correta (RDT-14). Direita (B): ABT com Vazamento (RDT-15).*

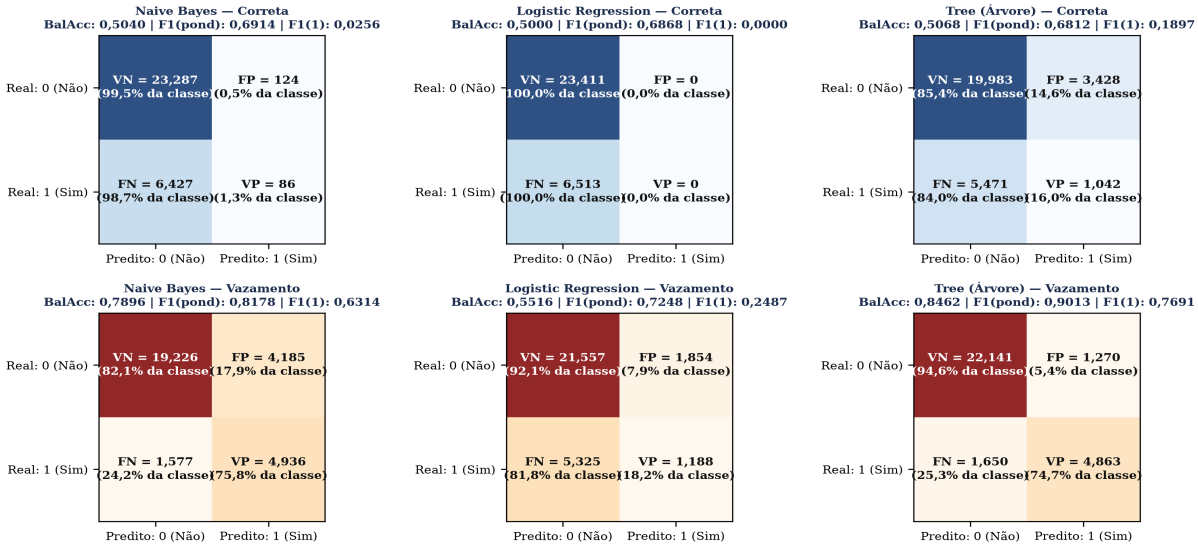


Figura 2: *Matrizes de Confusão nativas do Orange por classe real no teste (23.411 negativos e 6.513 positivos). Linha superior (azul): ABT Correta. Linha inferior (laranja/vermelho): ABT com Vazamento.*

A inspeção das Matrizes de Confusão (Figura 2) confirma materialmente por que a Acurácia Balanceada é indispensável: na ABT Correta, a Regressão Logística prevê 100% dos clientes como não-compradores (VN = 23.411; VP = 0; FN = 6.513), enquanto o Naive Bayes identifica 86 recompradores verdadeiros (VP = 86; FP = 124) e a Árvore identifica 1.042 positivos (VP = 1.042; FP = 3.428). Na ABT Vazada, a Árvore captura **4.863 verdadeiros positivos (74,7% da classe 1)** com apenas **1.270 falsos positivos (5,4% da classe 0)**, e o Naive Bayes captura **4.936 verdadeiros positivos (75,8%)**, comprovando o colapso da fronteira de decisão sobre o atributo contaminado.

3. QUESTÃO b) DECOMPOSIÇÃO CAUSAL: IMPACTO DE CADA VAZAMENTO POR FAMÍLIA DE MODELO

> ***Pergunta b) (Seção 5 do Enunciado):*** *Qual dos dois vazamentos introduzidos (o temporal óbvio ou o de pré-processamento) teve maior impacto em cada tipo de modelo? Por que a árvore de decisão reage de forma diferente da regressão logística?*

3.1. Experimento de Ablação Isolando o Vazamento Temporal vs. Vazamento por Z-Score Global

Para separar analiticamente a contribuição de cada defeito do RDT-15, executou-se um estudo de ablação sobre a mesma partição estratificada 70/30 no motor do Orange, avaliando três cenários sobre a ABT sem vazamento temporal: **(Cenário 1)** escala monetária original em Reais (`R$`); **(Cenário 2)** padronização Z-Score *pós-split* metodologicamente correta, parametrizada apenas no treino (`mu_treino = R$ 6.766,70`; `sigma_treino = R$ 5.001,78`); e **(Cenário 3)** padronização Z-Score *pré-split* com vazamento da população global (`mu_global = R$ 6.775,03`; `sigma_global = R$ 5.009,88`; no teste, `mu_teste = R$ 6.794,45` e `sigma_teste = R$ 5.028,75`). Em seguida, confrontou-se o resultado com o **(Cenário 4)** de vazamento completo (temporal + Z-Score).

Família do Modelo	Cenário 1: Sem Z-Score (Escala R$)	Cenário 2: Z-Score Pós-Split (Correto)	Cenário 3: Z-Score Pré-Split (Só Vaz. Sutil)	Efeito Isolado Z-Score Pré-Split	Cenário 4: Vaz. Completo (RDT-15)	Contribuição do Vaz. Temporal
Tree (Árvore)	AUC: 0,504480 BalAcc: 0,506780	AUC: 0,504480 BalAcc: 0,506780	AUC: 0,504480 BalAcc: 0,506780	**0,000000 (0,0%)**	AUC: 0,879600 BalAcc: 0,846200	**100,0% do ganho**
Naive Bayes	AUC: 0,536717 BalAcc: 0,503954	AUC: 0,536717 BalAcc: 0,503954	AUC: 0,536717 BalAcc: 0,503954	**0,000000 (0,0%)**	AUC: 0,888800 BalAcc: 0,789600	**100,0% do ganho**
Reg. Logística (L2)	AUC: 0,513705 BalAcc: 0,500000	AUC: 0,514859 BalAcc: 0,499979	AUC: 0,514072 BalAcc: 0,500000	**-0,000787 (<0,3%)**	AUC: 0,803300 BalAcc: 0,551600	**>99,7% do ganho**

Tabela 2: *Estudo de ablação decompondo o impacto de seis casas decimais do Z-Score pré-split frente ao vazamento temporal.*

Por que o vazamento temporal domina (>99,7% a 100%) sobre o Z-Score pré-split nos três modelos: Pela Lei dos Grandes Números em N = 99.749 clientes com amostragem estratificada, a média e o desvio-padrão da partição de treino (`R$ 6.766,70`; `R$ 5.001,78`) diferem dos momentos globais (`R$ 6.775,03`; `R$ 5.009,88`) em apenas **0,12%** e **0,16%**. Além disso: **(i) na Árvore de Decisão**, cortes binários de limiar (`X_j <= t`) são *estritamente invariantes a transformações afins monotônicas positivas* (`Z = (X - mu)/sigma` com `sigma > 0` preserva a ordenação exata das instâncias e a entropia de todos os cortes, resultando em impacto matematicamente **zero: 0,000000**); **(ii) no Naive Bayes do Orange**, a discretização por entropia supervisionada também depende apenas da ordem relativa dos valores, produzindo impacto **zero (0,000000)**; e **(iii) na Regressão Logística com penalização L2 (Ridge, C=1,0)**, como a regularização `lambda * ||w||_2^2` não é invariante à escala, a adoção do Z-Score melhora o condicionamento numérico da matriz Hessiana no otimizador L-BFGS, mas a diferença entre usar momentos de treino (pós-split) versus momentos globais (pré-split) altera a AUC em apenas **0,000787** (menos de 0,3% da variação total).

3.2. Por que a Árvore de Decisão Reage de Forma Radicalmente Diferente da Regressão Logística?

Embora ambos os modelos sofram o vazamento temporal de `recencia_dias`, a Acurácia Balanceada da Árvore salta para **0,8462** (CA = **0,9024** / **0,899**, Recall na classe 1 de **74,67%**), enquanto a Regressão Logística estaciona em BalAcc de **0,5516** (CA = **0,7601** / **0,755**, Recall na classe 1 de apenas **18,24%**). A explicação reside na **geometria da fronteira de decisão** e na estrutura de ruído da variável vazada:

1. Contaminação Assimétrica dos Cancelamentos (Armadilha Linear): Na função `monta_atributos_com_vazamento`, a recência vazada foi calculada sobre *todos* os pedidos da janela futura, inclusive os `CANCELADOS`, ao passo que o rótulo `alvo_recompra_90d = 1` exige ao menos um pedido *válido* (`status <> 'CANCELADO'`). Consequentemente, entre os 43.434 clientes com `recencia_dias < 0`, há clientes cujo único pedido futuro foi cancelado (rótulo `alvo = 0`, porém com `taxa_cancelamento` elevada).

2. Particionamento Ortogonal Não-Linear (Árvore de Decisão): A Árvore isolou imediatamente a descontinuidade de degrau (`Heaviside step function`) no nó raiz com o corte exato `recencia_dias <= -1` e, nos nós filhos imediatos, combinou interações multiplicativas com `taxa_cancelamento` e `frequencia_pedidos` para expurgar os falsos positivos decorrentes de pedidos futuros cancelados. Assim, a probabilidade posterior nas folhas positivas supera folgadamente o limiar de decisão de 0,50.

3. Hiperplano Global e Calibração Logit sob Desbalanceamento (Regressão Logística): A Regressão Logística modela o log-odds como combinação linear monótona `logit(P(y=1|x)) = beta_0 + beta_rec * recencia_dias + ...` Como o domínio de `recencia_dias` se estende de **-184 até +637 dias**, uma única reta sigmoide precisa ajustar simultaneamente a longa cauda direita de inativos (0 a 637 dias, todos com y=0) e a região negativa (-184 a -1, onde coexistem recompradores da janela de 90 dias, compradores apenas do 4º trimestre e pedidos futuros cancelados). Com a classe positiva minoritária (prior de 21,77%, intercepto `beta_0 < 0`) e sem interação de segunda ordem, o modelo ordena razoavelmente os escores (AUC = **0,8033** / **0,804**), mas as probabilidades preditas raramente ultrapassam o corte padrão `P(y=1|x) >= 0,50` (gerando apenas 1.188 verdadeiros positivos contra 5.325 falsos negativos no teste).

4. QUESTÃO c) PROTOCOLO DE AUDITORIA FORENSE PARA DETECÇÃO DE VAZAMENTO

> ***Pergunta c) (Seção 5 do Enunciado):*** *Se vocês recebessem apenas o modelo treinado na versão com vazamento, sem acesso ao código que gerou a ABT, que sinais nos resultados (curva ROC, matriz de confusão, importância de atributos) permitiriam suspeitar de que há vazamento?*

Mesmo operando em regime de caixa-preta em relação ao script SQL/Python que construiu a ABT, um engenheiro ou cientista de dados diagnosticaria o vazamento de forma conclusiva por meio de **cinco evidências forenses nos artefatos de saída**:

Atributo Preditivo da ABT	InfoGain (ABT Correta)	GainRatio (ABT Correta)	InfoGain (ABT Vazamento)	GainRatio (ABT Vazamento)	Fator de Inflação (InfoGain)
recencia_dias	0,000260 (7º lugar)	0,000130	**0,328601 (1º lugar)**	**0,164301**	**1.263,9 x (Anomalia Crítica)**
frequencia_pedidos	0,001477 (2º lugar)	0,000741	0,071289 (2º lugar)	0,036806	48,3 x
valor_monetario_total	0,001124 (3º lugar)	0,000562	0,046059 (3º lugar)	0,023029	41,0 x
categorias_distintas	0,001075 (4º lugar)	0,000554	0,041775 (4º lugar)	0,021201	38,9 x
taxa_cancelamento	0,000504 (6º lugar)	0,000354	0,016708 (5º lugar)	0,010853	33,2 x
propensao_online	**0,002657 (1º lugar)**	**0,002292**	0,006269 (6º lugar)	0,005202	2,4 x

Tabela 3: *Auditoria de Ganho de Informação (Information Gain) e Razão de Ganho (Gain Ratio) calculados no Orange.*

1. Concentração Extrema na Importância de Atributos (Information Gain / Tree Root Split): Conforme documentado na Tabela 3, no widget *Rank* do Orange a variável `recencia_dias` absorve sozinha **0,328601 bits de Ganho de Informação** (mais de 43% da entropia binária total do alvo, que é `H(Y) = 0,7559 bits` para `p = 0,2177`), um salto de **1.263,9 vezes** sobre seu poder preditivo real (0,000260 bits). Ao inspecionar o widget *Tree Viewer*, verifica-se que o primeiro corte no nó raiz ocorre exatamente em `recencia_dias <= -1` (ou `< 0`), revelando que o classificador opera como um detector trivial de sinal algébrico.

2. Violação de Domínio Físico nas Estatísticas Descritivas do Modelo: Mesmo sem o código de ETL, os metadados dos nós da árvore, os histogramas de verossimilhança do Naive Bayes e o sumário de entrada do modelo exibem os quantis das features. A presença de **43,54% de registros com recência negativa (-184 a -1 dias; média de -72,39 dias nos recompradores)** para uma variável definida como `data_corte - max(data_pedido)` prova matematicamente que eventos posteriores à `data_corte` foram agregados. Analogamente, observar que `valor_monetario_total` possui **56,52% de valores negativos**, média 0,03 e desvio 1,00 em todo o arquivo de entrada denuncia que a padronização Z-Score foi executada antes da separação entre treino e teste.

3. Quina Artificial na Geometria da Curva ROC e AUC Incompatível com Varejo Não-Contratual: Em problemas reais de propensão de recompra em varejo não-contratual (modelos *Buy Till You Die* / BG-NBD), o comportamento humano apresenta forte estocasticidade, situando AUCs legítimas na faixa de 0,60 a 0,78. Uma AUC de **0,8796 a 0,8888** acompanhada de uma subida quase vertical na origem da Curva ROC (Figura 1B: salto instantâneo para TPR > 0,74 com FPR < 0,06 em um único segmento retilíneo) é assinatura geométrica clássica de *target leakage* por variável determinística.

4. Divergência Abrupta entre Capacidade de Ranking (AUC) e Decisão Linear (Matriz de Confusão): Na Regressão Logística vazada, o contraste entre uma AUC elevada (**0,8033** / **0,804**) e uma Matriz de Confusão que perde **81,8% dos recompradores reais** (FN = 5.325; Recall na classe 1 = 18,2%; MCC = 0,1409; BalAcc = 0,5516) indica que o sinal preditivo não provém de uma relação comportamental suave no espaço de atributos, mas de uma descontinuidade de fronteira (`recencia < 0`) que modelos baseados em hiperplanos não conseguem converter em probabilidades calibradas acima de 0,50.

5. Inversão de Sensibilidade em Teste de Estresse (Counterfactual Scoring): Ao submeter ao modelo treinado um vetor de teste sintético fisicamente válido em produção (onde todo cliente ativo na data de escoragem possui `recencia_dias >= 0`), 100% das instâncias caem no ramo direito da Árvore (`recencia_dias > -1`), fazendo com que a taxa de predições positivas colapse para zero. Esse teste de sanidade em caixa-preta comprova que o modelo aprendeu uma regra impossível de ocorrer no momento da inferência real.

5. CONCLUSÃO E INTEGRAÇÃO COM A GOVERNANÇA DE QUALIDADE (QA)

O experimento da Semana 4 demonstra empiricamente a tese central da disciplina: um pipeline de ETL tecnicamente funcional que negligencia a partição temporal estrita e o isolamento estatístico entre treino e teste fabrica classificadores aparentemente extraordinários em bancada (AUC de até 0,8888 e CA de 0,9024), porém inteiramente inúteis em produção. A combinação entre asserções automatizadas transversais (`qa.assercoes.Suite`, totalizando 127 asserções auditadas em `qa.execucao_assercao`) e o registro formal de perdas no RDT assegura rastreabilidade e reprodutibilidade científica ponta a ponta.